

Proyecto Final

Juan Alberto Martinez Lopez / Alberto Armijo Ruiz

27 de mayo de 2017

```
#Librerías utilizadas.
```

```
library("caret")
```

```
## Loading required package: lattice
```

```
## Loading required package: ggplot2
```

```
library("leaps")
```

```
library("e1071")
```

```
library("ROCR")
```

```
## Loading required package: gplots
```

```
##
```

```
## Attaching package: 'gplots'
```

```
## The following object is masked from 'package:stats':
```

```
##
```

```
##      lowess
```

```
library("randomForest")
```

```
## randomForest 4.6-12
```

```
## Type rfNews() to see new features/changes/bug fixes.
```

```
##
```

```
## Attaching package: 'randomForest'
```

```
## The following object is masked from 'package:ggplot2':
```

```
##
```

```
##      margin
```

```
library("neuralnet")
```

```
##
```

```
## Attaching package: 'neuralnet'
```

```
## The following object is masked from 'package:ROCR':
```

```
##
```

```
##      prediction
```

```
library("ada")
```

```
## Loading required package: rpart
```

```
set.seed(1)
```

1. default of credit card clients Data Set (Clasificación)

Introducción.

La base de datos se centra en el caso de los pagos por defecto de los clientes en Taiwán y compara la probabilidad de que un usuario pague o no pague según datos de pagos anteriores. Desde la perspectiva de la gestión de riesgos, la peor predicción errónea es considerar que un cliente pagará cuando es falso. Las características son:

Limit_bat: Cantidad de credito bancario dado(en dolares), incluye el credito individual y de su familia. Sex: genero (0 = mujer, 1 = hombre). Education: Educación recibida en 4 variables: Others: Otros estudios. University: Estudios universitarios. High school: Estudios preparatoria. school: Estudios básicos. Marriage: Estado marital en 3 variables: Married: Casado. Single: soltero. Others: otros. Age: Edad. Pay_1-6: Historia del pago anterior. Cada variable es un mes distinto. La escala de medición para el estado de pago es: -1 = pagar debidamente; 1 = retraso de pago de un mes; 2 = retardo de pago por dos meses... Bill_Amt1-6: Estado de la cuenta actual. Pay_Amt1-6: Pago realizado en ese mes. default payment next month: Variable que aprendemos, basamos si la persona pagará o no el siguiente mes.

Nuestro objetivo será intentar conseguir una predicción lo mejor posibles, intentando minimizar los falsos positivos (predecimos que un cliente pagará, pero no este no paga).

Lectura de la base de datos.

Para la lectura de la base de datos, hemos tenido que transformar el archivo a .csv y además borrar la primera fila por problemas de lectura.

```
credit_card = read.csv("default_of_credict_card_clients.csv",
                      , sep="," , header = TRUE, row.names =1)
attach(credit_card)
summary(credit_card)
```

##	LIMIT_BAL	SEX	EDUCATION	MARRIAGE
##	Min. : 10000	Min. :1.000	Min. :0.000	Min. :0.000
##	1st Qu.: 50000	1st Qu.:1.000	1st Qu.:1.000	1st Qu.:1.000
##	Median : 140000	Median :2.000	Median :2.000	Median :2.000
##	Mean : 167484	Mean :1.604	Mean :1.853	Mean :1.552
##	3rd Qu.: 240000	3rd Qu.:2.000	3rd Qu.:2.000	3rd Qu.:2.000
##	Max. :1000000	Max. :2.000	Max. :6.000	Max. :3.000
##	AGE	PAY_0	PAY_2	PAY_3
##	Min. :21.00	Min. : -2.0000	Min. : -2.0000	Min. : -2.0000
##	1st Qu.:28.00	1st Qu.: -1.0000	1st Qu.: -1.0000	1st Qu.: -1.0000
##	Median :34.00	Median : 0.0000	Median : 0.0000	Median : 0.0000
##	Mean :35.49	Mean : -0.0167	Mean : -0.1338	Mean : -0.1662
##	3rd Qu.:41.00	3rd Qu.: 0.0000	3rd Qu.: 0.0000	3rd Qu.: 0.0000
##	Max. :79.00	Max. : 8.0000	Max. : 8.0000	Max. : 8.0000
##	PAY_4	PAY_5	PAY_6	BILL_AMT1
##	Min. : -2.0000	Min. : -2.0000	Min. : -2.0000	Min. : -165580
##	1st Qu.: -1.0000	1st Qu.: -1.0000	1st Qu.: -1.0000	1st Qu.: 3559
##	Median : 0.0000	Median : 0.0000	Median : 0.0000	Median : 22382
##	Mean : -0.2207	Mean : -0.2662	Mean : -0.2911	Mean : 51223
##	3rd Qu.: 0.0000	3rd Qu.: 0.0000	3rd Qu.: 0.0000	3rd Qu.: 67091
##	Max. : 8.0000	Max. : 8.0000	Max. : 8.0000	Max. : 964511
##	BILL_AMT2	BILL_AMT3	BILL_AMT4	BILL_AMT5
##	Min. : -69777	Min. : -157264	Min. : -170000	Min. : -81334

```
## 1st Qu.: 2985    1st Qu.: 2666    1st Qu.: 2327    1st Qu.: 1763
## Median : 21200   Median : 20089   Median : 19052   Median : 18105
## Mean   : 49179   Mean   : 47013   Mean   : 43263   Mean   : 40311
## 3rd Qu.: 64006   3rd Qu.: 60165   3rd Qu.: 54506   3rd Qu.: 50191
## Max.   :983931   Max.   :1664089   Max.   : 891586   Max.   :927171
## BILL_AMT6      PAY_AMT1      PAY_AMT2      PAY_AMT3
## Min.   : -339603   Min.   : 0       Min.   : 0       Min.   : 0
## 1st Qu.: 1256     1st Qu.: 1000    1st Qu.: 833     1st Qu.: 390
## Median : 17071    Median : 2100    Median : 2009    Median : 1800
## Mean   : 38872    Mean   : 5664    Mean   : 5921    Mean   : 5226
## 3rd Qu.: 49198    3rd Qu.: 5006    3rd Qu.: 5000    3rd Qu.: 4505
## Max.   : 961664    Max.   :873552    Max.   :1684259   Max.   :896040
## PAY_AMT4      PAY_AMT5      PAY_AMT6
## Min.   : 0       Min.   : 0.0     Min.   : 0.0
## 1st Qu.: 296     1st Qu.: 252.5   1st Qu.: 117.8
## Median : 1500    Median : 1500.0   Median : 1500.0
## Mean   : 4826    Mean   : 4799.4   Mean   : 5215.5
## 3rd Qu.: 4013    3rd Qu.: 4031.5   3rd Qu.: 4000.0
## Max.   :621000    Max.   :426529.0   Max.   :528666.0
## default.payment.next.month
## Min.   :0.0000
## 1st Qu.:0.0000
## Median :0.0000
## Mean   :0.2212
## 3rd Qu.:0.0000
## Max.   :1.0000
```

Creación de los conjuntos de training y test.

Para el training, utilizaremos el 70% de los datos, y dejaremos el 30% restante para el test.

```
set.seed(1)
train = sample(nrow(credit_card), round(nrow(credit_card)*0.7))
credit_card.train = credit_card[train,]
credit_card.test = credit_card[-train,]
```

2. Preprocesado de los datos.

Lo primero que queremos hacer es comprobar si hay datos perdidos, y si es así; reemplazaremos el valor perdido.

```
anyNA(credit_card.train)
```

```
## [1] FALSE
```

Como no tenemos ningún dato perdido, no tendremos que reemplazar los valores. Si hubiéramos tenido valores tenidos, podríamos haber utilizado la función *knnImputation* para reemplazar los valores perdidos por los k vecinos más cercanos (por defecto la función utiliza k=3). También podríamos utilizar la media como sustituto de un valor perdido.

Lo siguiente que vamos a hacer es modificar aquellas columnas que separan los datos en “clases” como por ejemplo la columna *EDUCATION*, que indica que tipo de estudios tiene cada persona. Por cada tipo en los que los separe, crearemos una nueva columna que indique con 0s y 1s la pertenencia a ese tipo. También tenemos que realizar este proceso con la columna *MARRIAGE*

```
# Modificamos la columna 2, llamada sex, para dividir los datos en 0=mujer, 1=hombre.
credit_card.train$SEX = ifelse(credit_card.train$SEX == 2, 0, 1)
```

```
# También tenemos que modificar la columna EDUCATION, la dividiremos en cuatro columnas diferentes:
# ed.other, ed.university, ed.high_school, ed.school
ed.other = ifelse(credit_card.train$EDUCATION == 4, 1, 0)
ed.university = ifelse(credit_card.train$EDUCATION == 2, 1, 0)
ed.high_school = ifelse(credit_card.train$EDUCATION == 3 | credit_card.train$EDUCATION == 2, 1, 0)
ed.school = ifelse(credit_card.train$EDUCATION == 1 | credit_card.train$EDUCATION == 2 | credit_card.train$EDUCATION == 3, 1, 0)

credit_card.train = cbind(credit_card.train, ed.other, ed.high_school, ed.school, ed.university)
```

```
# Borramos la columna EDUCATION.
credit_card.train = credit_card.train[, -which(colnames(credit_card.train) == "EDUCATION")]
```

```
# También tenemos que modificar la columna marriage. Introduciremos tres nueva columnas: marriage.married, marriage.single, marriage.others
marriage.married = ifelse(credit_card.train$MARRIAGE == 1, 1, 0)
marriage.single = ifelse(credit_card.train$MARRIAGE == 2, 1, 0)
marriage.others = ifelse(credit_card.train$MARRIAGE == 3, 1, 0)
```

```
# Introducimos los datos.
credit_card.train = cbind(credit_card.train, marriage.married, marriage.single, marriage.others)
```

```
# Borramos la variable MARRIAGE.
credit_card.train = credit_card.train[, -which(colnames(credit_card.train) == "MARRIAGE")]
```

También vamos a cambiar el nombre de la columna *PAY0* por *PAY1*.

```
colnames(credit_card.train)[which(colnames(credit_card.train)=="PAY_0")]="PAY_1"
```

Por último, utilizaremos la función *preProcess* para aplicar la transformación *BoxCox* a las variables que tengan una varianza elevada.

```
# Por Último, utilizamos la función preProcess.
trans = preProcess(credit_card.train, c("BoxCox") )
trainTransformado = predict(trans, credit_card.train)
summary(trainTransformado)
```

##	LIMIT_BAL	SEX	AGE	PAY_1
##	Min. : 49.50	Min. : 0.0000	Min. : 1.564	Min. : -2.00000
##	1st Qu.: 82.29	1st Qu.: 0.0000	1st Qu.: 1.622	1st Qu.: -1.00000
##	Median : 113.27	Median : 0.0000	Median : 1.657	Median : 0.00000
##	Mean : 111.23	Mean : 0.3974	Mean : 1.656	Mean : -0.01524
##	3rd Qu.: 133.74	3rd Qu.: 1.0000	3rd Qu.: 1.688	3rd Qu.: 0.00000
##	Max. : 206.99	Max. : 1.0000	Max. : 1.775	Max. : 8.00000
##	PAY_2	PAY_3	PAY_4	PAY_5
##	Min. : -2.0000	Min. : -2.0000	Min. : -2.000	Min. : -2.0000
##	1st Qu.: -1.0000	1st Qu.: -1.0000	1st Qu.: -1.000	1st Qu.: -1.0000
##	Median : 0.0000	Median : 0.0000	Median : 0.000	Median : 0.0000
##	Mean : -0.1321	Mean : -0.1697	Mean : -0.221	Mean : -0.2678
##	3rd Qu.: 0.0000	3rd Qu.: 0.0000	3rd Qu.: 0.000	3rd Qu.: 0.0000
##	Max. : 8.0000	Max. : 8.0000	Max. : 8.000	Max. : 8.0000
##	PAY_6	BILL_AMT1	BILL_AMT2	BILL_AMT3
##	Min. : -2.000	Min. : -154973	Min. : -69777	Min. : -46127
##	1st Qu.: -1.000	1st Qu.: 3508	1st Qu.: 2956	1st Qu.: 2552
##	Median : 0.000	Median : 22143	Median : 20895	Median : 20012

```
## Mean      :-0.289      Mean      : 51238      Mean      : 49092      Mean      : 47104
## 3rd Qu.: 0.000      3rd Qu.: 66175      3rd Qu.: 62795      3rd Qu.: 59674
## Max.      : 8.000      Max.      : 964511      Max.      : 983931      Max.      : 1664089
## BILL_AMT4      BILL_AMT5      BILL_AMT6      PAY_AMT1
## Min.      :-170000      Min.      : -81334      Min.      : -339603      Min.      : 0
## 1st Qu.: 2276      1st Qu.: 1730      1st Qu.: 1261      1st Qu.: 1000
## Median : 19044      Median : 18093      Median : 17036      Median : 2100
## Mean      : 43452      Mean      : 40395      Mean      : 38948      Mean      : 5608
## 3rd Qu.: 53536      3rd Qu.: 49719      3rd Qu.: 48740      3rd Qu.: 5006
## Max.      : 891586      Max.      : 927171      Max.      : 961664      Max.      : 493358
## PAY_AMT2      PAY_AMT3      PAY_AMT4      PAY_AMT5
## Min.      : 0.0      Min.      : 0      Min.      : 0      Min.      : 0.0
## 1st Qu.: 809.8      1st Qu.: 390      1st Qu.: 300      1st Qu.: 269.8
## Median : 2000.0      Median : 1794      Median : 1500      Median : 1500.0
## Mean      : 5988.9      Mean      : 5218      Mean      : 4793      Mean      : 4838.0
## 3rd Qu.: 5000.0      3rd Qu.: 4525      3rd Qu.: 4010      3rd Qu.: 4037.8
## Max.      : 1684259.0      Max.      : 896040      Max.      : 528897      Max.      : 426529.0
## PAY_AMT6      default.payment.next.month      ed.other
## Min.      : 0      Min.      : 0.0000      Min.      : 0.000000
## 1st Qu.: 100      1st Qu.: 0.0000      1st Qu.: 0.000000
## Median : 1500      Median : 0.0000      Median : 0.000000
## Mean      : 5252      Mean      : 0.2209      Mean      : 0.003857
## 3rd Qu.: 4000      3rd Qu.: 0.0000      3rd Qu.: 0.000000
## Max.      : 528666      Max.      : 1.0000      Max.      : 1.000000
## ed.high_school      ed.school      ed.university      marriage.married
## Min.      : 0.0000      Min.      : 0.0000      Min.      : 0.0000      Min.      : 0.000
## 1st Qu.: 0.0000      1st Qu.: 1.0000      1st Qu.: 0.0000      1st Qu.: 0.000
## Median : 1.0000      Median : 1.0000      Median : 0.0000      Median : 0.000
## Mean      : 0.6332      Mean      : 0.9844      Mean      : 0.4708      Mean      : 0.458
## 3rd Qu.: 1.0000      3rd Qu.: 1.0000      3rd Qu.: 1.0000      3rd Qu.: 1.000
## Max.      : 1.0000      Max.      : 1.0000      Max.      : 1.0000      Max.      : 1.000
## marriage.single      marriage.others
## Min.      : 0.0000      Min.      : 0.000000
## 1st Qu.: 0.0000      1st Qu.: 0.000000
## Median : 1.0000      Median : 0.000000
## Mean      : 0.5296      Mean      : 0.01076
## 3rd Qu.: 1.0000      3rd Qu.: 0.000000
## Max.      : 1.0000      Max.      : 1.000000
```

Para no tener que repetir este mismo proceso cuando vayamos a calcular el error fuera de la muestra de entrenamiento, vamos a crear una función que se encargue directamente de ello.

Para hacer más sencillo hacer las transformaciones al conjunto de test, se crearán funciones para reemplazar las columnas.

Función para reemplazar las columnas.

```
reemplazarCol = function(x){
  # Columna SEX
  x$SEX = ifelse(x$SEX == 2, 0, 1)

  # Columna EDUCATION.
  ed.other = ifelse(x$EDUCATION == 4, 1, 0)
  ed.university = ifelse(x$EDUCATION == 2, 1, 0)
  ed.high_school = ifelse(x$EDUCATION == 3 | x$EDUCATION == 2, 1, 0)
  ed.school = ifelse(x$EDUCATION == 1 | x$EDUCATION == 2 | x$EDUCATION == 3, 1, 0)
  x = cbind(x, ed.other, ed.high_school, ed.school, ed.university)
```

```

# Borramos la columna EDUCATION.
x = x[,-which(colnames(x) == "EDUCATION")]

# Columna MARRIAGE.
marriage.married = ifelse(x$MARRIAGE == 1, 1,0)
marriage.single = ifelse(x$MARRIAGE == 2, 1,0)
marriage.others = ifelse(x$MARRIAGE == 3, 1,0)

# Introducimos los datos.
x = cbind(x, marriage.married, marriage.single, marriage.others)

# Borramos la variable MARRIAGE.
x = x[,-which(colnames(x) == "MARRIAGE")]

# Cambiamos el nombre de la variables PAY_0.
colnames(x)[which(colnames(x)=="PAY_0")]="PAY_1"
x
}

# Función que realiza la transformación BoxCox.
preprocesar = function(x,pred=trans){
  transTest = predict(pred, x)
  transTest
}

# Función que engloba las funciones anteriores.
prepareTest = function(x){
  tr = reemplazarCol(x)
  tr= preprocesar(x)
  tr
}

```

Por último, vamos a utilizar el filtro PCA para comprobar si todos los datos son relevantes. Si encontramos algún dato redundante, lo eliminaremos de nuestro conjunto de datos. Para saber si un dato es redundante, debemos comprobar si todos los atributos PC (PC1, PC2, ..., PCx) son 0 o muy cercanos a 0; si encontramos algún atributo PC que se aleje de 0, no podemos asegurar que el atributo sea redundante, y por lo tanto no lo podremos quitar.

```

pcaTransformation = prcomp(trainTransformado[, -default.payment.next.month], center=F, scale=F)
pcaTransformation$rotation

```

##	PC1	PC2	PC3
## SEX	-1.246341e-06	-4.904872e-07	6.438891e-07
## AGE	-4.969286e-06	-4.554302e-07	2.875395e-06
## PAY_1	-8.402099e-07	-1.174667e-06	-3.702498e-06
## PAY_2	-7.831655e-07	-1.423524e-06	-4.412710e-06
## PAY_3	-6.673071e-07	-4.589883e-07	-3.545257e-06
## PAY_4	-5.207917e-07	1.417210e-06	-1.570775e-06
## PAY_5	-4.037429e-07	2.881611e-06	-2.724843e-06
## PAY_6	-3.766899e-07	3.805578e-06	-4.208659e-06
## BILL_AMT1	-4.504475e-01	-5.518948e-01	-1.939668e-01
## BILL_AMT2	-4.392710e-01	-4.001284e-01	-5.929929e-02
## BILL_AMT3	-4.267653e-01	-3.653856e-02	5.589409e-01
## BILL_AMT4	-3.965494e-01	2.495663e-01	7.254672e-02

## BILL_AMT5	-3.674088e-01	4.259793e-01	-2.116082e-01
## BILL_AMT6	-3.519808e-01	4.823144e-01	-3.119262e-01
## PAY_AMT1	-3.243380e-02	2.060446e-02	1.527775e-01
## PAY_AMT2	-3.775548e-02	1.711008e-01	6.730651e-01
## PAY_AMT3	-3.242933e-02	1.224791e-01	-3.265661e-03
## PAY_AMT4	-2.677187e-02	9.158369e-02	-5.831541e-02
## PAY_AMT5	-2.730621e-02	6.424338e-02	3.452144e-02
## PAY_AMT6	-2.977955e-02	-1.973644e-02	1.347066e-01
## default.payment.next.month	-6.351776e-07	-4.214420e-08	-3.104142e-07
## ed.other	-9.624187e-09	-2.745489e-08	2.474927e-08
## ed.high_school	-1.896296e-06	-6.830605e-07	4.915918e-07
## ed.school	-2.934032e-06	-1.293661e-07	1.589245e-06
## ed.university	-1.456700e-06	-4.301804e-07	2.616470e-07
## marriage.married	-1.425640e-06	-7.724235e-08	9.020876e-07
## marriage.single	-1.540599e-06	-1.426100e-07	8.016949e-07
## marriage.others	-2.413312e-08	-4.908935e-08	2.310480e-08
##	PC4	PC5	PC6
## SEX	-3.566762e-06	-1.520925e-06	5.286491e-07
## AGE	-1.461946e-05	-5.976859e-06	3.173099e-06
## PAY_1	8.990123e-06	5.326504e-06	-2.426989e-06
## PAY_2	1.002619e-05	6.261145e-06	-3.382277e-06
## PAY_3	1.159672e-05	5.567521e-06	2.979077e-06
## PAY_4	1.226031e-05	6.646866e-06	4.967272e-07
## PAY_5	1.250268e-05	3.280485e-06	-1.587765e-06
## PAY_6	1.088009e-05	5.014483e-06	-8.464995e-07
## BILL_AMT1	-2.931502e-01	-3.297459e-03	-4.848133e-01
## BILL_AMT2	3.499226e-02	-2.453157e-02	5.131682e-01
## BILL_AMT3	2.082730e-01	2.751252e-01	5.838854e-02
## BILL_AMT4	3.800910e-01	-4.508734e-01	-1.622145e-01
## BILL_AMT5	6.119784e-02	-9.923400e-02	-6.073123e-03
## BILL_AMT6	-2.494273e-01	3.956564e-01	6.400747e-02
## PAY_AMT1	-1.580537e-01	-1.890328e-01	5.668722e-01
## PAY_AMT2	-2.936760e-01	8.716394e-02	-2.619771e-01
## PAY_AMT3	-2.448393e-01	-5.475542e-01	-1.790583e-01
## PAY_AMT4	-3.731955e-01	-3.350907e-03	7.561300e-02
## PAY_AMT5	-4.698687e-01	1.592771e-01	6.227597e-02
## PAY_AMT6	-3.575028e-01	-4.306835e-01	1.900638e-01
## default.payment.next.month	-2.441713e-07	8.554837e-08	1.441512e-07
## ed.other	-5.952895e-08	-6.177029e-08	-4.029573e-08
## ed.high_school	-4.060606e-06	-9.485931e-07	7.318980e-07
## ed.school	-8.651648e-06	-3.320632e-06	2.003742e-06
## ed.university	-3.086885e-06	-7.760970e-07	5.044920e-07
## marriage.married	-3.977989e-06	-1.701712e-06	6.245093e-07
## marriage.single	-4.704388e-06	-1.882783e-06	1.280249e-06
## marriage.others	-1.013772e-07	7.803180e-09	-1.311795e-08
##	PC7	PC8	PC9
## SEX	-1.174610e-07	1.187276e-06	-7.100879e-07
## AGE	1.514887e-07	3.516323e-06	-2.187484e-06
## PAY_1	-7.950970e-07	-3.288392e-06	2.428264e-06
## PAY_2	-8.862946e-07	-4.894956e-06	1.669249e-06
## PAY_3	1.712987e-07	-3.554414e-06	1.068221e-06
## PAY_4	-1.059430e-06	-5.071150e-06	2.949098e-06
## PAY_5	9.871106e-07	-3.844836e-06	5.277723e-06
## PAY_6	-3.233630e-06	-2.176669e-06	4.700824e-06

## BILL_AMT1	-5.784232e-02	2.612453e-02	1.639371e-01
## BILL_AMT2	7.860051e-02	1.918421e-01	3.484413e-02
## BILL_AMT3	-6.908146e-02	-1.534870e-01	-3.474197e-01
## BILL_AMT4	2.872122e-01	-1.086755e-01	-1.511017e-01
## BILL_AMT5	-4.807444e-01	1.034837e-01	1.026033e-01
## BILL_AMT6	2.294940e-01	-1.042140e-01	2.420389e-01
## PAY_AMT1	9.399958e-02	3.042951e-01	2.706315e-01
## PAY_AMT2	-6.229616e-02	2.569055e-01	3.745537e-01
## PAY_AMT3	2.838555e-01	3.527173e-01	-1.530299e-01
## PAY_AMT4	-4.703760e-01	2.596694e-01	-6.002146e-01
## PAY_AMT5	4.883207e-01	-1.949813e-01	-3.736668e-01
## PAY_AMT6	-2.577384e-01	-7.191139e-01	1.497786e-01
## default.payment.next.month	-1.028962e-07	-2.499193e-07	-1.679699e-07
## ed.other	4.080268e-08	7.368398e-08	-9.062423e-08
## ed.high_school	3.044095e-08	1.277443e-06	-1.851432e-07
## ed.school	8.033230e-08	1.986790e-06	-1.117627e-06
## ed.university	2.021123e-07	5.957239e-07	-7.079063e-08
## marriage.married	-4.819974e-07	1.138148e-06	-7.005156e-07
## marriage.single	5.108585e-07	9.349753e-07	-5.659778e-07
## marriage.others	6.052524e-08	2.104871e-08	-6.005771e-08
##	PC10	PC11	PC12
## SEX	2.036624e-06	-7.436572e-07	1.129676e-06
## AGE	8.792866e-06	-3.923402e-06	2.457274e-06
## PAY_1	-4.146034e-06	2.369751e-06	-2.616384e-06
## PAY_2	-6.314026e-06	4.068402e-06	-1.224670e-06
## PAY_3	-5.350430e-06	1.189033e-06	-1.563536e-06
## PAY_4	-2.355507e-06	2.953267e-06	2.803969e-08
## PAY_5	-4.564415e-06	1.561645e-06	-2.916779e-06
## PAY_6	-6.017116e-06	4.932324e-07	8.077485e-07
## BILL_AMT1	2.478302e-01	-2.037808e-01	6.647957e-03
## BILL_AMT2	-3.210795e-01	4.804633e-01	1.101541e-02
## BILL_AMT3	-1.827823e-01	-4.374404e-01	-8.857876e-02
## BILL_AMT4	3.769429e-01	2.292044e-01	2.989633e-01
## BILL_AMT5	6.006808e-02	7.354659e-02	-6.031386e-01
## BILL_AMT6	-1.972868e-01	-1.425941e-01	3.767805e-01
## PAY_AMT1	4.808991e-01	-4.325673e-01	8.535603e-03
## PAY_AMT2	-4.298254e-03	3.726952e-01	6.866880e-02
## PAY_AMT3	-5.275991e-01	-2.733176e-01	-1.031887e-01
## PAY_AMT4	1.413774e-01	9.280919e-02	4.061418e-01
## PAY_AMT5	2.639755e-01	2.206015e-01	-4.576697e-01
## PAY_AMT6	-1.347172e-01	4.938737e-04	8.378889e-02
## default.payment.next.month	1.118034e-07	1.525853e-07	-1.476304e-07
## ed.other	-5.982512e-08	-1.087642e-07	-1.822524e-08
## ed.high_school	2.824303e-06	-1.328202e-06	2.085331e-06
## ed.school	5.245684e-06	-2.347095e-06	1.718855e-06
## ed.university	2.245202e-06	-4.064207e-07	1.662469e-06
## marriage.married	2.420860e-06	-1.849774e-06	2.169335e-07
## marriage.single	2.849312e-06	-3.909275e-07	1.299498e-06
## marriage.others	2.200491e-08	-1.101321e-07	-1.341060e-08
##	PC13	PC14	PC15
## SEX	-4.994388e-02	1.758165e-01	2.101293e-02
## AGE	-2.596834e-01	6.524050e-01	1.111274e-01
## PAY_1	2.845449e-01	2.077701e-01	-6.139335e-01
## PAY_2	3.829019e-01	1.854558e-01	-4.240037e-01

## PAY_3	4.076562e-01	1.668681e-01	-1.036243e-01
## PAY_4	4.146728e-01	1.292552e-01	2.389101e-01
## PAY_5	4.050352e-01	8.311893e-02	3.917349e-01
## PAY_6	3.947186e-01	5.291373e-02	4.403649e-01
## BILL_AMT1	1.198614e-05	-6.690806e-06	1.697121e-06
## BILL_AMT2	-4.397442e-06	-1.336072e-06	2.072544e-06
## BILL_AMT3	-4.387547e-06	-5.561526e-07	2.887197e-07
## BILL_AMT4	3.533276e-07	-2.319828e-06	-2.162308e-06
## BILL_AMT5	-5.729437e-06	-6.515125e-07	-1.071000e-06
## BILL_AMT6	-4.331925e-06	-3.200078e-06	-2.163376e-06
## PAY_AMT1	2.204872e-05	-8.197985e-06	-5.764811e-06
## PAY_AMT2	1.028501e-05	-1.219756e-06	-1.911368e-06
## PAY_AMT3	1.398044e-05	4.959350e-08	-1.034443e-06
## PAY_AMT4	2.118311e-05	-5.844697e-06	-1.279737e-06
## PAY_AMT5	1.554901e-05	-3.765884e-06	1.462420e-06
## PAY_AMT6	8.854075e-06	-3.437856e-06	-1.349495e-06
## default.payment.next.month	3.565418e-03	1.389473e-01	-5.492867e-02
## ed.other	-1.083454e-03	1.140839e-04	2.688836e-04
## ed.high_school	-7.551419e-02	3.187417e-01	4.941901e-02
## ed.school	-1.531398e-01	3.949888e-01	6.825188e-02
## ed.university	-5.780995e-02	2.414498e-01	4.875016e-02
## marriage.married	-7.853307e-02	1.762228e-01	1.671912e-02
## marriage.single	-7.627864e-02	2.129252e-01	5.047921e-02
## marriage.others	-1.034405e-03	5.002343e-03	3.949675e-04
##	PC16	PC17	PC18
## SEX	1.627752e-02	8.750777e-02	-6.665852e-02
## AGE	-2.995491e-03	5.744671e-02	-6.626594e-02
## PAY_1	-6.173908e-01	6.414465e-02	-2.587711e-01
## PAY_2	2.871176e-01	-2.202249e-02	5.427556e-01
## PAY_3	5.637225e-01	-3.201344e-02	-1.454100e-01
## PAY_4	1.583899e-01	-1.742211e-02	-5.598575e-01
## PAY_5	-1.962281e-01	1.550347e-02	-5.120993e-02
## PAY_6	-3.779363e-01	1.789307e-02	4.471568e-01
## BILL_AMT1	9.071210e-07	1.563716e-07	-1.181259e-06
## BILL_AMT2	-2.002981e-06	-4.971292e-07	1.673945e-07
## BILL_AMT3	-1.182029e-06	7.465039e-07	1.339919e-06
## BILL_AMT4	-1.326285e-07	-4.726019e-07	1.113125e-06
## BILL_AMT5	2.382202e-06	2.480886e-07	-2.326239e-07
## BILL_AMT6	9.022128e-07	-1.679566e-07	-1.558364e-06
## PAY_AMT1	-1.194680e-06	-2.048297e-07	2.436347e-06
## PAY_AMT2	1.247216e-06	-4.297826e-07	-2.029782e-07
## PAY_AMT3	5.342328e-07	-1.082609e-07	-1.891098e-06
## PAY_AMT4	-1.664132e-06	-1.993218e-07	-8.711472e-07
## PAY_AMT5	-2.171168e-06	-7.178214e-07	1.838785e-06
## PAY_AMT6	-6.307774e-07	-4.082202e-07	-3.308277e-08
## default.payment.next.month	-7.173902e-02	-8.771720e-04	-5.920080e-02
## ed.other	-7.705337e-04	1.797029e-03	-2.304360e-03
## ed.high_school	4.699754e-03	-2.166173e-01	1.747435e-01
## ed.school	9.975398e-04	4.730832e-02	-2.564323e-02
## ed.university	8.158430e-03	-1.705680e-01	2.176285e-01
## marriage.married	-5.806579e-02	-6.455242e-01	-8.811367e-02
## marriage.single	5.742924e-02	6.982767e-01	5.131589e-02
## marriage.others	-2.065799e-04	-1.827002e-03	-8.426785e-04
##	PC19	PC20	PC21

## SEX	-3.011371e-01	-5.439066e-02	-9.269997e-01
## AGE	-2.605972e-01	2.322482e-03	2.268556e-01
## PAY_1	1.030241e-01	1.444884e-01	-1.842676e-02
## PAY_2	-1.848766e-01	-4.601682e-01	5.295734e-02
## PAY_3	-9.123618e-03	6.248619e-01	-3.065796e-03
## PAY_4	1.689886e-01	-3.203558e-01	-1.227148e-04
## PAY_5	4.500454e-03	-3.466360e-01	4.049519e-02
## PAY_6	-1.704839e-01	3.882150e-01	-1.424139e-02
## BILL_AMT1	5.299544e-07	1.303697e-06	2.534744e-07
## BILL_AMT2	-3.737755e-07	-1.141532e-06	2.102662e-07
## BILL_AMT3	1.286125e-07	-7.714272e-07	-2.177252e-07
## BILL_AMT4	-5.381460e-07	1.608945e-06	2.150151e-08
## BILL_AMT5	1.224179e-06	-2.527579e-07	-6.550249e-07
## BILL_AMT6	-9.827655e-08	-8.248516e-07	-6.730994e-08
## PAY_AMT1	7.972164e-07	-2.254360e-06	-2.572910e-07
## PAY_AMT2	6.795517e-08	1.892255e-06	1.468281e-07
## PAY_AMT3	1.843346e-06	-9.428161e-07	-4.989937e-08
## PAY_AMT4	1.167263e-06	-1.423284e-06	5.328227e-07
## PAY_AMT5	4.860265e-07	1.235560e-06	-5.761471e-07
## PAY_AMT6	8.858846e-07	4.280460e-07	-3.692929e-07
## default.payment.next.month	-8.387689e-02	1.283156e-02	6.368024e-02
## ed.other	-5.287202e-03	8.967046e-04	-5.917765e-05
## ed.high_school	5.012724e-01	7.962890e-03	-1.206010e-01
## ed.school	-1.267566e-01	3.491108e-03	1.384555e-01
## ed.university	6.150463e-01	1.401235e-02	-1.904139e-01
## marriage.married	-2.690614e-01	-2.538711e-03	7.052401e-02
## marriage.single	1.174594e-01	5.750873e-04	7.215873e-02
## marriage.others	3.094603e-03	3.576971e-03	-2.084945e-03
##	PC22	PC23	PC24
## SEX	-2.272875e-02	-7.700855e-03	-1.221135e-02
## AGE	1.563736e-02	1.275858e-01	6.968118e-02
## PAY_1	-2.515380e-02	1.190260e-01	8.279088e-03
## PAY_2	1.133896e-01	5.308730e-03	8.391557e-03
## PAY_3	-2.535791e-01	1.969639e-02	6.448905e-03
## PAY_4	5.328498e-01	-1.617403e-02	7.003669e-03
## PAY_5	-7.145802e-01	4.150947e-02	4.710116e-03
## PAY_6	3.523879e-01	-1.360022e-02	-3.681348e-03
## BILL_AMT1	-2.313214e-07	-6.527956e-07	3.440264e-08
## BILL_AMT2	1.999122e-07	1.954971e-07	-5.419416e-08
## BILL_AMT3	-3.088154e-07	-1.540538e-08	1.553855e-07
## BILL_AMT4	5.348892e-07	-9.749554e-08	-2.426431e-07
## BILL_AMT5	6.851993e-07	-1.891170e-08	-2.367308e-07
## BILL_AMT6	-1.038164e-06	-3.287585e-09	7.421536e-08
## PAY_AMT1	6.217775e-07	-1.035258e-06	-3.598166e-08
## PAY_AMT2	-7.740161e-07	-2.707333e-07	-7.879775e-08
## PAY_AMT3	2.481757e-06	-2.825527e-07	7.292261e-09
## PAY_AMT4	-3.089837e-06	-2.474531e-07	-1.977012e-08
## PAY_AMT5	1.119133e-06	-2.857288e-07	-4.870618e-07
## PAY_AMT6	-2.829919e-07	-1.951784e-07	-3.777309e-07
## default.payment.next.month	-4.800197e-02	-9.774235e-01	-7.388131e-03
## ed.other	1.287133e-04	2.006302e-03	7.356346e-03
## ed.high_school	-1.058611e-02	-1.286482e-02	-7.377545e-01
## ed.school	9.579186e-03	6.751613e-02	2.515492e-02
## ed.university	-1.166051e-02	-5.175566e-02	6.642126e-01

## marriage.married	-1.885696e-03	6.257076e-02	8.768240e-02
## marriage.single	7.377785e-03	1.502572e-02	8.398431e-03
## marriage.others	3.679473e-03	-2.343316e-03	-2.774480e-02
##	PC25	PC26	PC27
## SEX	-1.098827e-03	-9.080783e-03	-1.157969e-03
## AGE	6.552254e-02	4.633396e-01	1.661856e-01
## PAY_1	-2.668582e-04	-1.975495e-03	-3.450206e-06
## PAY_2	1.762340e-03	3.197400e-03	-4.811322e-04
## PAY_3	-2.006863e-03	5.812044e-04	4.312657e-04
## PAY_4	-1.713267e-03	-1.433924e-03	-7.021459e-04
## PAY_5	4.996782e-03	1.125720e-03	-3.671973e-04
## PAY_6	-3.357714e-03	1.973568e-03	1.212946e-03
## BILL_AMT1	-1.616656e-08	-1.106234e-07	-5.425752e-09
## BILL_AMT2	5.079917e-08	-2.879529e-08	-3.599314e-08
## BILL_AMT3	-3.631167e-08	-8.000041e-08	4.779923e-08
## BILL_AMT4	5.283877e-08	-1.715224e-08	-3.930950e-08
## BILL_AMT5	5.696305e-08	-2.114595e-08	-5.038830e-08
## BILL_AMT6	-6.921757e-08	2.245749e-07	5.992019e-08
## PAY_AMT1	-2.370285e-08	4.074902e-08	-3.536513e-09
## PAY_AMT2	3.617539e-08	5.421583e-09	-4.055122e-08
## PAY_AMT3	-1.590220e-08	-2.214886e-07	7.734258e-08
## PAY_AMT4	4.652286e-08	-9.243737e-09	8.456886e-09
## PAY_AMT5	-6.327530e-08	-1.044964e-07	-3.507302e-08
## PAY_AMT6	7.958019e-09	3.563298e-08	-3.530966e-08
## default.payment.next.month	-4.693718e-03	4.323984e-03	4.404874e-04
## ed.other	-7.698843e-02	3.299730e-01	-9.406210e-01
## ed.high_school	-4.431952e-02	1.706590e-02	1.336661e-04
## ed.school	2.933921e-01	-7.744452e-01	-2.940008e-01
## ed.university	2.240248e-02	1.100169e-02	3.112533e-03
## marriage.married	-3.919074e-01	-2.735200e-02	1.360402e-02
## marriage.single	-3.935797e-01	-1.743775e-03	2.221317e-02
## marriage.others	7.698497e-01	2.745588e-01	2.204228e-02
##	PC28		
## SEX	-2.526586e-03		
## AGE	3.154843e-01		
## PAY_1	4.450828e-04		
## PAY_2	-7.801586e-05		
## PAY_3	2.016428e-04		
## PAY_4	4.108864e-04		
## PAY_5	3.252575e-04		
## PAY_6	6.809812e-06		
## BILL_AMT1	4.225614e-09		
## BILL_AMT2	-1.503755e-08		
## BILL_AMT3	1.305471e-08		
## BILL_AMT4	-4.364877e-09		
## BILL_AMT5	-6.587599e-09		
## BILL_AMT6	-2.826747e-09		
## PAY_AMT1	-1.678314e-08		
## PAY_AMT2	-4.651063e-09		
## PAY_AMT3	-1.739533e-09		
## PAY_AMT4	4.393709e-09		
## PAY_AMT5	-8.656330e-09		
## PAY_AMT6	-8.000439e-09		
## default.payment.next.month	5.074205e-04		

```
## ed.other                1.804076e-02
## ed.high_school          -9.043577e-03
## ed.school               1.280622e-02
## ed.university           9.999352e-03
## marriage.married        -5.395885e-01
## marriage.single         -5.272744e-01
## marriage.others         -5.749932e-01
```

Según los resultados del filtro PCA, no hay ningún dato que sea redundante. Por lo tanto, no eliminaremos ninguno de los atributos del conjunto de datos.

Estudio de los parámetros e hiperparámetros.

Vamos a realizar un estudio sobre los parámetros para saber cuáles de ellos son los más importantes. Con los más importantes crearemos los modelos lineales que vamos a ajustar.

Con la función `regsubsets`, podemos encontrar que atributos son mejores a la hora de escogerlos antes.

```
muestra_regsubsets = regsubsets(default.payment.next.month ~ ., data = trainTransformado, nvmax = 28, m
summary((muestra_regsubsets))
```

```
## Subset selection object
## Call: regsubsets.formula(default.payment.next.month ~ ., data = trainTransformado,
##      nvmax = 28, method = "exhaustive")
## 28 Variables (and intercept)
##              Forced in Forced out
## LIMIT_BAL      FALSE      FALSE
## SEX            FALSE      FALSE
## AGE            FALSE      FALSE
## PAY_1          FALSE      FALSE
## PAY_2          FALSE      FALSE
## PAY_3          FALSE      FALSE
## PAY_4          FALSE      FALSE
## PAY_5          FALSE      FALSE
## PAY_6          FALSE      FALSE
## BILL_AMT1      FALSE      FALSE
## BILL_AMT2      FALSE      FALSE
## BILL_AMT3      FALSE      FALSE
## BILL_AMT4      FALSE      FALSE
## BILL_AMT5      FALSE      FALSE
## BILL_AMT6      FALSE      FALSE
## PAY_AMT1       FALSE      FALSE
## PAY_AMT2       FALSE      FALSE
## PAY_AMT3       FALSE      FALSE
## PAY_AMT4       FALSE      FALSE
## PAY_AMT5       FALSE      FALSE
## PAY_AMT6       FALSE      FALSE
## ed.other       FALSE      FALSE
## ed.high_school FALSE      FALSE
## ed.school       FALSE      FALSE
## ed.university  FALSE      FALSE
## marriage.married FALSE      FALSE
## marriage.single FALSE      FALSE
## marriage.others FALSE      FALSE
## 1 subsets of each size up to 28
```

```

## Selection Algorithm: exhaustive
##      LIMIT_BAL SEX AGE PAY_1 PAY_2 PAY_3 PAY_4 PAY_5 PAY_6 BILL_AMT1
## 1 ( 1 ) " " " " " " "*" " " " " " " " " " "
## 2 ( 1 ) " " " " " " "*" " " " " " " " " "*"
## 3 ( 1 ) " " " " " " "*" "*" " " " " " " " " "*"
## 4 ( 1 ) "*" " " " " " "*" "*" " " " " " " " " "*"
## 5 ( 1 ) "*" " " "*" "*" "*" " " " " " " " " "*"
## 6 ( 1 ) "*" " " "*" "*" "*" " " " " " " " " "*"
## 7 ( 1 ) "*" " " "*" "*" " " " "*" " " " " " " "*"
## 8 ( 1 ) "*" " " "*" "*" "*" " " " " "*" " " " " "*"
## 9 ( 1 ) "*" " " "*" "*" "*" " " " " "*" " " " " "*"
## 10 ( 1 ) "*" " " "*" "*" "*" "*" "*" " " " "*" " " " " "*"
## 11 ( 1 ) "*" "*" "*" "*" "*" "*" "*" " " " "*" " " " " "*"
## 12 ( 1 ) "*" "*" "*" "*" "*" "*" "*" " " " "*" " " " " "*"
## 13 ( 1 ) "*" "*" "*" "*" "*" "*" "*" " " " "*" " " " " "*"
## 14 ( 1 ) "*" "*" "*" "*" "*" "*" "*" " " " "*" " " " " "*"
## 15 ( 1 ) "*" "*" "*" "*" "*" "*" "*" " " " "*" " " " " "*"
## 16 ( 1 ) "*" "*" "*" "*" "*" "*" "*" " " " "*" " " " " "*"
## 17 ( 1 ) "*" "*" "*" "*" "*" "*" "*" " " " "*" " " " " "*"
## 18 ( 1 ) "*" "*" "*" "*" "*" "*" "*" " " " "*" " " " " "*"
## 19 ( 1 ) "*" "*" "*" "*" "*" "*" "*" "*" "*" " " " " " "*"
## 20 ( 1 ) "*" "*" "*" "*" "*" "*" "*" "*" "*" " " " " " "*"
## 21 ( 1 ) "*" "*" "*" "*" "*" "*" "*" "*" "*" " " " " " "*"
## 22 ( 1 ) "*" "*" "*" "*" "*" "*" "*" "*" "*" " " " " " "*"
## 23 ( 1 ) "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" " " " " "*"
## 24 ( 1 ) "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" " " " " "*"
## 25 ( 1 ) "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" " " " " "*"
## 26 ( 1 ) "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" " " " " "*"
## 27 ( 1 ) "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" " " " " "*"
## 28 ( 1 ) "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" "*" " " " " "*"
##      BILL_AMT2 BILL_AMT3 BILL_AMT4 BILL_AMT5 BILL_AMT6 PAY_AMT1
## 1 ( 1 ) " " " " " " " " " " " "
## 2 ( 1 ) " " " " " " " " " " " "
## 3 ( 1 ) " " " " " " " " " " " "
## 4 ( 1 ) " " " " " " " " " " " "
## 5 ( 1 ) " " " " " " " " " " " "
## 6 ( 1 ) " " " " " " " " " " " "
## 7 ( 1 ) " " " " " " " " " " "*"
## 8 ( 1 ) " " " " " " " " " " "*"
## 9 ( 1 ) " " " " " " " " " " "*"
## 10 ( 1 ) " " " " " " " " " " "*"
## 11 ( 1 ) " " " " " " " " " " "*"
## 12 ( 1 ) " " " " " " " " " " "*"
## 13 ( 1 ) " " " " " " " " " " "*"
## 14 ( 1 ) " " " " " " " " " " "*"
## 15 ( 1 ) " " " " " " " " " " "*"
## 16 ( 1 ) " " " " " " " " " " "*"
## 17 ( 1 ) "*" " " " " " " " " " " "*"
## 18 ( 1 ) "*" " " " " " " " " " " "*"
## 19 ( 1 ) "*" " " " " " " " " " " "*"
## 20 ( 1 ) "*" " " " " " " " " " " "*"
## 21 ( 1 ) "*" " " " " " " " " " " "*"
## 22 ( 1 ) "*" " " " " " " " " " " "*"
## 23 ( 1 ) "*" " " " " " " " " " " "*"

```

```

## 24 ( 1 ) "*"      " "      " "      "*"      " "      "*"
## 25 ( 1 ) "*"      " "      "*"      "*"      " "      "*"
## 26 ( 1 ) "*"      " "      "*"      "*"      "*"      "*"
## 27 ( 1 ) "*"      "*"      "*"      "*"      "*"      "*"
## 28 ( 1 ) "*"      "*"      "*"      "*"      "*"      "*"
##      PAY_AMT2 PAY_AMT3 PAY_AMT4 PAY_AMT5 PAY_AMT6 ed.other
## 1 ( 1 ) " "      " "      " "      " "      " "      " "
## 2 ( 1 ) " "      " "      " "      " "      " "      " "
## 3 ( 1 ) " "      " "      " "      " "      " "      " "
## 4 ( 1 ) " "      " "      " "      " "      " "      " "
## 5 ( 1 ) " "      " "      " "      " "      " "      " "
## 6 ( 1 ) " "      " "      " "      " "      " "      " "
## 7 ( 1 ) " "      " "      " "      " "      " "      " "
## 8 ( 1 ) " "      " "      " "      " "      " "      " "
## 9 ( 1 ) " "      " "      " "      " "      " "      " "
## 10 ( 1 ) " "      " "      " "      " "      " "      " "
## 11 ( 1 ) " "      " "      " "      " "      " "      " "
## 12 ( 1 ) "*"      " "      " "      " "      " "      " "
## 13 ( 1 ) "*"      " "      " "      " "      " "      " "
## 14 ( 1 ) "*"      " "      "*"      " "      " "      " "
## 15 ( 1 ) "*"      " "      " "      " "      " "      " "
## 16 ( 1 ) "*"      " "      "*"      " "      " "      " "
## 17 ( 1 ) "*"      " "      "*"      " "      " "      " "
## 18 ( 1 ) "*"      " "      "*"      "*"      " "      " "
## 19 ( 1 ) "*"      " "      "*"      "*"      " "      " "
## 20 ( 1 ) "*"      "*"      "*"      "*"      " "      " "
## 21 ( 1 ) "*"      "*"      "*"      "*"      "*"      " "
## 22 ( 1 ) "*"      "*"      "*"      "*"      "*"      "*"
## 23 ( 1 ) "*"      "*"      "*"      "*"      "*"      "*"
## 24 ( 1 ) "*"      "*"      "*"      "*"      "*"      "*"
## 25 ( 1 ) "*"      "*"      "*"      "*"      "*"      "*"
## 26 ( 1 ) "*"      "*"      "*"      "*"      "*"      "*"
## 27 ( 1 ) "*"      "*"      "*"      "*"      "*"      "*"
## 28 ( 1 ) "*"      "*"      "*"      "*"      "*"      "*"
##      ed.high_school ed.school ed.university marriage.married
## 1 ( 1 ) " "      " "      " "      " "
## 2 ( 1 ) " "      " "      " "      " "
## 3 ( 1 ) " "      " "      " "      " "
## 4 ( 1 ) " "      " "      " "      " "
## 5 ( 1 ) " "      " "      " "      " "
## 6 ( 1 ) " "      "*"      " "      " "
## 7 ( 1 ) " "      "*"      " "      " "
## 8 ( 1 ) " "      "*"      " "      " "
## 9 ( 1 ) " "      "*"      " "      "*"
## 10 ( 1 ) " "      "*"      " "      "*"
## 11 ( 1 ) " "      "*"      " "      "*"
## 12 ( 1 ) " "      "*"      " "      "*"
## 13 ( 1 ) "*"      "*"      " "      "*"
## 14 ( 1 ) "*"      "*"      " "      "*"
## 15 ( 1 ) "*"      "*"      " "      "*"
## 16 ( 1 ) "*"      "*"      " "      "*"
## 17 ( 1 ) "*"      "*"      " "      "*"
## 18 ( 1 ) "*"      "*"      " "      "*"
## 19 ( 1 ) "*"      "*"      " "      "*"

```

```
## 20 ( 1 ) "*"          "*"          " "          "*"
## 21 ( 1 ) "*"          "*"          " "          "*"
## 22 ( 1 ) "*"          "*"          " "          "*"
## 23 ( 1 ) "*"          "*"          " "          "*"
## 24 ( 1 ) "*"          "*"          " "          "*"
## 25 ( 1 ) "*"          "*"          " "          "*"
## 26 ( 1 ) "*"          "*"          " "          "*"
## 27 ( 1 ) "*"          "*"          " "          "*"
## 28 ( 1 ) "*"          "*"          "*"          "*"
##
##      marriage.single marriage.others
## 1 ( 1 ) " "          " "
## 2 ( 1 ) " "          " "
## 3 ( 1 ) " "          " "
## 4 ( 1 ) " "          " "
## 5 ( 1 ) " "          " "
## 6 ( 1 ) " "          " "
## 7 ( 1 ) " "          " "
## 8 ( 1 ) " "          " "
## 9 ( 1 ) " "          " "
## 10 ( 1 ) " "          " "
## 11 ( 1 ) " "          " "
## 12 ( 1 ) " "          " "
## 13 ( 1 ) " "          " "
## 14 ( 1 ) " "          " "
## 15 ( 1 ) "*"          "*"
## 16 ( 1 ) "*"          "*"
## 17 ( 1 ) "*"          "*"
## 18 ( 1 ) "*"          "*"
## 19 ( 1 ) "*"          "*"
## 20 ( 1 ) "*"          "*"
## 21 ( 1 ) "*"          "*"
## 22 ( 1 ) "*"          "*"
## 23 ( 1 ) "*"          "*"
## 24 ( 1 ) "*"          "*"
## 25 ( 1 ) "*"          "*"
## 26 ( 1 ) "*"          "*"
## 27 ( 1 ) "*"          "*"
## 28 ( 1 ) "*"          "*"

```

```
reg.summary = summary(muestra_regsubsets)
```

Ahora, calcularemos los valores mínimos de los criterios cp y BIC. Utilizaremos estos dos valores para probar diferentes modelos.



```
par(mfrow=c(1,2))
plot(reg.summary$cp, xlab="number of variables", ylab="cp", type="l")
which.min(reg.summary$cp)

```

```
## [1] 17
```

```
plot(reg.summary$bic, xlab="number of variables", ylab="BIC", type="l")

```



```
which.min(reg.summary$bic)
```

```
## [1] 9
```

```
par(mfrow=c(1,1) )
```

Según los resultados obtenidos, los dos mejores conjuntos de datos son de tamaño 17 y de tamaño 9. Tomaremos los atributos en el orden que aparecen en la salida de la función regsubsets.

Modelos lineales.

Para hacer más sencillo el cálculo del error teniendo un modelo, crearemos funciones para calcular el error, para calcular el conjunto de datos precedidos, y otra que las englobe.

```
# Función para calcular la solución dada una predicción.
calculateSol = function(x){
  prediction.model = rep(0,length(x))
  prediction.model[x >= 0.5] = 1

  prediction.model
}

# Función para calcular el Error.
calculateErrorClasification = function(calculated.solution, real.sol){
  er = sum(calculated.solution != real.sol)/length(calculated.solution)
  er
}
```



```
# Función que calcula el Error pasándole la predicción.
calculateError = function(model.prediction, labels){
  pred = calculateSol(model.prediction)
  return(calculateErrorClasification(pred, labels))
}
```

Transformamos los valores de test.

```
testTransformado = reemplazarCol(credit_card.test)
testTransformado = predict(trans, testTransformado)
summary(testTransformado)
```

```
##      LIMIT_BAL      SEX      AGE      PAY_1
## Min.   : 49.50   Min.   :0.0000   Min.   :1.564   Min.   : -2.00000
## 1st Qu.: 82.29   1st Qu.:0.0000   1st Qu.:1.622   1st Qu.: -1.00000
## Median :113.27   Median :0.0000   Median :1.657   Median : 0.00000
## Mean   :111.07   Mean    :0.3936   Mean    :1.656   Mean    : -0.02011
## 3rd Qu.:132.00   3rd Qu.:1.0000   3rd Qu.:1.688   3rd Qu.: 0.00000
## Max.   :193.37   Max.    :1.0000   Max.    :1.769   Max.    : 8.00000
##      PAY_2      PAY_3      PAY_4      PAY_5
## Min.   : -2.0000   Min.   : -2.000   Min.   : -2.00   Min.   : -2.0000
## 1st Qu.: -1.0000   1st Qu.: -1.000   1st Qu.: -1.00   1st Qu.: -1.0000
## Median : 0.0000   Median : 0.000   Median : 0.00   Median : 0.0000
## Mean   : -0.1377   Mean    : -0.158   Mean    : -0.22   Mean    : -0.2626
## 3rd Qu.: 0.0000   3rd Qu.: 0.000   3rd Qu.: 0.00   3rd Qu.: 0.0000
## Max.   : 7.0000   Max.    : 7.000   Max.    : 7.00   Max.    : 7.0000
##      PAY_6      BILL_AMT1      BILL_AMT2      BILL_AMT3
## Min.   : -2.000   Min.   : -165580   Min.   : -67526   Min.   : -157264
## 1st Qu.: -1.000   1st Qu.: 3692     1st Qu.: 3024     1st Qu.: 2905
## Median : 0.000   Median : 22984    Median : 21933    Median : 20309
## Mean   : -0.296   Mean    : 51189    Mean    : 49383    Mean    : 46801
## 3rd Qu.: 0.000   3rd Qu.: 68619    3rd Qu.: 66224    3rd Qu.: 61433
## Max.   : 7.000   Max.    : 621749    Max.    : 577681    Max.    : 855086
##      BILL_AMT4      BILL_AMT5      BILL_AMT6      PAY_AMT1
## Min.   : -17250   Min.   : -37594   Min.   : -39046   Min.   : 0
## 1st Qu.: 2444     1st Qu.: 1865     1st Qu.: 1229     1st Qu.: 1000
## Median : 19063    Median : 18135    Median : 17132    Median : 2194
## Mean   : 42821    Mean    : 40115    Mean    : 38695    Mean    : 5793
## 3rd Qu.: 56095    3rd Qu.: 51333    3rd Qu.: 50140    3rd Qu.: 5006
## Max.   : 565669    Max.    : 587067    Max.    : 527566    Max.    : 873552
##      PAY_AMT2      PAY_AMT3      PAY_AMT4      PAY_AMT5
## Min.   : 0.0      Min.   : 0      Min.   : 0      Min.   : 0.0
## 1st Qu.: 918.5     1st Qu.: 390     1st Qu.: 264     1st Qu.: 211.5
## Median : 2057.5    Median : 1913    Median : 1549    Median : 1530.5
## Mean   : 5763.2    Mean    : 5243    Mean    : 4903    Mean    : 4709.2
## 3rd Qu.: 5000.0    3rd Qu.: 4500    3rd Qu.: 4024    3rd Qu.: 4022.5
## Max.   :1215471.0   Max.    :889043    Max.    :621000    Max.    :317077.0
##      PAY_AMT6      default.payment.next.month      ed.other
## Min.   : 0      Min.   :0.0000      Min.   :0.000000
## 1st Qu.: 166     1st Qu.:0.0000      1st Qu.:0.000000
## Median : 1500    Median :0.0000      Median :0.000000
## Mean   : 5131    Mean    :0.2219      Mean    :0.004667
## 3rd Qu.: 4012    3rd Qu.:0.0000      3rd Qu.:0.000000
## Max.   :351282    Max.    :1.0000      Max.    :1.000000
```

```
## ed.high_school    ed.school    ed.university    marriage.married
## Min.      :0.0000    Min.      :0.0000    Min.      :0.0000    Min.      :0.0000
## 1st Qu.:0.0000    1st Qu.:1.0000    1st Qu.:0.0000    1st Qu.:0.0000
## Median :1.0000    Median :1.0000    Median :0.0000    Median :0.0000
## Mean      :0.6278    Mean      :0.9843    Mean      :0.4603    Mean      :0.4491
## 3rd Qu.:1.0000    3rd Qu.:1.0000    3rd Qu.:1.0000    3rd Qu.:1.0000
## Max.      :1.0000    Max.      :1.0000    Max.      :1.0000    Max.      :1.0000
## marriage.single marriage.others
## Min.      :0.0000    Min.      :0.00000
## 1st Qu.:0.0000    1st Qu.:0.00000
## Median :1.0000    Median :0.00000
## Mean      :0.5381    Mean      :0.01078
## 3rd Qu.:1.0000    3rd Qu.:0.00000
## Max.      :1.0000    Max.      :1.00000
```

Ahora, pasaremos a probar diferentes modelos lineales. Para ello utilizaremos la función glm, que utiliza regresión logística. Una vez hecho esto, nos quedaremos con el modelo que menor error fuera de la muestra obtenga y que sea más sencillo. Calcularemos también el error dentro de la muestra para comprobar que ambos valores son cercanos y que no hay sobreajuste en el modelo.

Por último, calcularemos la curva ROC y el área del modelo que hayamos seleccionado.

```
m1 = glm(default.payment.next.month~LIMIT_BAL+SEX+PAY_3+PAY_4+PAY_5+PAY_6+BILL_AMT1+BILL_AMT2+BILL_AMT3
```

```
## Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
```

```
predtr.m1 = predict(m1, trainTransformado)
Ein.m1 = calculateError(predtr.m1, trainTransformado$default.payment.next.month)
Ein.m1
```

```
## [1] 0.2172857
```

```
pred.m1 = predict(m1, testTransformado)
Eout.m1 = calculateError(pred.m1, testTransformado$default.payment.next.month)
Eout.m1
```

```
## [1] 0.2196667
```

```
m2 = glm(default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_AMT1+PAY_5+marriage
predtr.m2 = predict(m2, trainTransformado)
Ein.m2 = calculateError(predtr.m2, trainTransformado$default.payment.next.month)
Ein.m2
```

```
## [1] 0.208
```

```
pred.m2 = predict(m2, testTransformado)
Eout.m2 = calculateError(pred.m2, testTransformado$default.payment.next.month)
Eout.m2
```

```
## [1] 0.2111111
```

```
m3= glm(default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_AMT1+PAY_5+marriage
predtr.m3 = predict(m3, trainTransformado)
Ein.m3 = calculateError(predtr.m3, trainTransformado$default.payment.next.month)
Ein.m3
```

```
## [1] 0.2091905
```

```
pred.m3 = predict(m3, testTransformado)
Eout.m3 = calculateError(pred.m3, testTransformado$default.payment.next.month)
Eout.m3
```


```
## [1] 0.2117778
```

Nuestro mejor modelo es el tercer modelo, ya que es el más simple de los 3 y obtiene resultados casi iguales que los anteriores. La diferencia entre el error dentro de la muestra y fuera de la muestra son muy parecidos, por lo tanto, el modelo no presenta sobreajuste. Ahora pasaremos a calcular la curva ROC de este modelo (utilizamos las probabilidades para calcular la curva ROC, para ello utilizamos la librería ROCR. Primero calculamos las probabilidades del modelo y con estas dibujamos la curva ROC), y también calcularemos el área debajo de la curva.

```
linear.model = ROCR::prediction(pred.m3, testTransformado$default.payment.next.month)
perf = performance(linear.model, "tpr", "fpr")
auc.linear = performance(linear.model, measure = "auc")
print(auc.linear@y.values[[1]])
```

```
## [1] 0.7182492
```

```
plot(perf)
```



Modelos Boosting.

Para crear los modelos del boosting, utilizaremos la biblioteca ada, que contiene la función ada la cuál implementa el algoritmo adaboost. Uno de los parámetros de este algoritmo indica el número de clasificadores que se van a utilizar para separar los datos de la muestra; probaremos varios números de clasificadores. Nos quedaremos con el clasificador que menor error fuera de la muestra cometa. También calcularemos su curva ROC, y calcularemos cuál es el área de esta.

```
bt1 = ada::ada(default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_AMT1+PAY_5+
pred.bt1 = predict(bt1, trainTransformado)
Ein.bt1 = mean(pred.bt1 != trainTransformado$default.payment.next.month)
Ein.bt1
```

```
## [1] 0.1778095
```

```
predTs.bt1 = predict(bt1, testTransformado)
Eout.bt1 = mean(predTs.bt1 != testTransformado$default.payment.next.month)
Eout.bt1
```

```
## [1] 0.182
```

```
bt2 = ada::ada(formula = default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_A
pred.bt2 = predict(bt2, trainTransformado)
Ein.bt2 = mean(pred.bt2 != trainTransformado$default.payment.next.month)
Ein.bt2
```

```
## [1] 0.1780476
```

```
predTs.bt2 = predict(bt2, testTransformado)
Eout.bt2 = mean(predTs.bt2 != testTransformado$default.payment.next.month)
Eout.bt2
```

```
## [1] 0.1827778
```

```
bt3 = ada::ada(formula=default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_AMT
pred.bt3 = predict(bt3, trainTransformado)
Ein.bt3 = mean(pred.bt3 != trainTransformado$default.payment.next.month)
Ein.bt3
```

```
## [1] 0.179381
```

```
predTs.bt3 = predict(bt3, testTransformado)
Eout.bt3 = mean(predTs.bt3 != testTransformado$default.payment.next.month)
Eout.bt3
```


```
## [1] 0.1827778
```

Como los errores son todos muy parecidos entre ellos, nos quedaremos con el modelo más sencillo, el cuál es el modelo 3; ya que es el que menos clasificadores utiliza. Ahora calcularemos su curva ROC y el area debajo de esta.

```
predi = predict(bt3, testTransformado, type = "probs")
salida.boosting = predi[,2]
boosting.model = ROCR::prediction(salida.boosting, testTransformado$default.payment.next.month)
perf.boost = performance(boosting.model, "tpr", "fpr")
auc.boosting = performance(boosting.model, measure = "auc")
print(auc.boosting@y.values[[1]])
```

```
## [1] 0.6797438
```

```
plot(perf.boost)
```



Modelos Redes Neuronales

Para crear los modelos del Redes Neuronales, utilizaremos la biblioteca `neuralnet`, que contiene la función `neuralnet` la cuál implementa el algoritmo `backpropagation`. Los parametros utilizados en este algoritmo son: `hidden` = indica el número de capas ocultas y los nodos que contiene en cada capa que se van a utilizar para separar los datos de la muestra; probaremos con distintas capas; `stepmax` = fija el número máximo de pasos para el entrenamiento de las redes neuronales; `threshold` = es el umbral que limita el valor de las derivadas parciales de la función de error usandolo como criterio de parada. Nos quedaremos con la red que menor error fuera de la muestra cometa. También calcularemos su curva ROC, y calcularemos cuál es el área de esta.

```
nn1 = neuralnet(formula = default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_5,
data=trainTransformado,
size=c(5,5),
weights.init = function() {0.1},
stepmax = 1000,
threshold = 0.01,
verbose = TRUE)

plot(nn1)

n <- c("PAY_1", "PAY_2", "BILL_AMT1", "LIMIT_BAL", "AGE", "ed.school", "PAY_AMT1", "PAY_5", "marriage.married")

pred.nn1 = compute(nn1, trainTransformado[names(trainTransformado) %in% n])

pred.nn1_ = pred.nn1$net.result*(max(pred.nn1$net.result)-min(pred.nn1$net.result))+min(pred.nn1$net.result)

calculateError(pred.nn1_,trainTransformado$default.payment.next.month)

## [1] 0.2209047619
```

```

pred.nn1Ts = compute(nn1, testTransformado[names(testTransformado) %in% n])

pred.nn1_test = pred.nn1Ts$net.result*(max(pred.nn1Ts$net.result)-min(pred.nn1Ts$net.result))+min(pred.nn1Ts$net.result)

calculateError(pred.nn1_test,testTransformado$default.payment.next.month)

## [1] 0.2218888889

nn2 = neuralnet(formula = default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_1,
data=trainTransformado,
plot=TRUE,
plotfn=plot.nn2)

plot(nn2)

pred.nn2 = compute(nn2, trainTransformado[names(trainTransformado) %in% n])

pred.nn2_ = pred.nn2$net.result*(max(pred.nn2$net.result)-min(pred.nn2$net.result))+min(pred.nn2$net.result)

calculateError(pred.nn2_,trainTransformado$default.payment.next.month)

## [1] 0.3118571429

pred.nn2Ts = compute(nn2, testTransformado[names(testTransformado) %in% n])

pred.nn2_test = pred.nn2Ts$net.result*(max(pred.nn2Ts$net.result)-min(pred.nn2Ts$net.result))+min(pred.nn2Ts$net.result)

calculateError(pred.nn2_test,testTransformado$default.payment.next.month)

## [1] 0.2505555556

nn3 = neuralnet(formula = default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_1,
data=trainTransformado,
plot=TRUE,
plotfn=plot.nn3)

plot(nn3)

pred.nn3 = compute(nn3, trainTransformado[names(trainTransformado) %in% n])

pred.nn3_ = pred.nn3$net.result*(max(pred.nn3$net.result)-min(pred.nn3$net.result))+min(pred.nn3$net.result)

calculateError(pred.nn3_,trainTransformado$default.payment.next.month)

## [1] 0.2223809524

pred.nn3Ts = compute(nn3, testTransformado[names(testTransformado) %in% n])

pred.nn3_test = pred.nn3Ts$net.result*(max(pred.nn3Ts$net.result)-min(pred.nn3Ts$net.result))+min(pred.nn3Ts$net.result)

calculateError(pred.nn3_test,testTransformado$default.payment.next.month)

## [1] 0.2228888889

nn4 = neuralnet(formula = default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_1,
data=trainTransformado,
plot=TRUE,
plotfn=plot.nn4)

plot(nn4)

pred.nn4 = compute(nn4, trainTransformado[names(trainTransformado) %in% n])

pred.nn4_ = pred.nn4$net.result*(max(pred.nn4$net.result)-min(pred.nn4$net.result))+min(pred.nn4$net.result)

```

```

calculateError(pred.nn4_,trainTransformado$default.payment.next.month)

## [1] 0.2251428571

pred.nn4Ts = compute(nn4, testTransformado[names(testTransformado) %in% n])

pred.nn4_test = pred.nn4Ts$net.result*(max(pred.nn4Ts$net.result)-min(pred.nn4Ts$net.result))+min(pred.nn4Ts$net.result)

calculateError(pred.nn4_test,testTransformado$default.payment.next.month)

## [1] 0.2252222222

```

Podemos observar que los errores son casi iguales y se diferencian muy poco. Esto es debido a que por la necesidad de eficiencia en tiempo hemos aumentado mucho el valor de la variable threshold, cuyo valor mejoraría bastante el error con un $[0,1,0.01]$, lo que creemos que repercute en el error que comete. Dado que las redes neuronales necesitan mas tiempo de entrenamiento que el que les hemos podido proporcionar. Por último creemos que los errores son muy parecidos entre los modelos puede ser debido, además de que el umbral threshold es muy alto, las capas ocultas son muy parecidas.

En este caso, el mejor modelo es el tercero, ya que es el que tiene una cantidad muy pequeña menos de error y consume menos tiempo de ejecución. Ahora calcularemos su curva ROC.


```

probsnn = compute(nn3, testTransformado[names(testTransformado) %in% n])
probsnn.pred = probsnn$net.result
nn.model = ROCR::prediction(probsnn.pred, testTransformado$default.payment.next.month)
perfnn = performance(nn.model, "tpr", "fpr")
auc.nn = performance(nn.model, measure = "auc")
print(auc.nn@y.values[[1]])

## [1] 0.4732142838

plot(perfnn)

```



Modelos con clasificador SVM.

Para utilizar el clasificador SVM, utilizaremos el paquete *e1071*, dentro de este se encuentra la función `svm`, esta por defecto utiliza un kernel gaussiano. La fórmula que utilizaremos será la misma que las anteriormente utilizadas. Probaremos con diferentes valores para este parámetro y nos quedaremos con el mejor de ellos.

Después, calcularemos la curva ROC del modelado elegido.

```
svm1 = e1071::svm(formula=default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_1,
                  data=trainTransformado, kernel="gaussian", gamma=0.001)

pred.svm1 = predict(svm1, trainTransformado)
predTs.svm1 = predict(svm1, testTransformado)
Ein.svm1 = mean(pred.svm1 != trainTransformado$default.payment.next.month)
Eout.svm1 = mean(predTs.svm1 != testTransformado$default.payment.next.month)
Ein.svm1

## [1] 0.1755238095
Eout.svm1

## [1] 0.1814444444

svm2 = e1071::svm(formula=default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_1,
                  data=trainTransformado, kernel="gaussian", gamma=0.001)

pred.svm2 = predict(svm2, trainTransformado)
predTs.svm2 = predict(svm2, testTransformado)
Ein.svm2 = mean(pred.svm2 != trainTransformado$default.payment.next.month)
```



```
Eout.svm2 = mean(predTs.svm2 != testTransformado$default.payment.next.month)
Ein.svm2
```

```
## [1] 0.1779047619
```

```
Eout.svm2
```

```
## [1] 0.1818888889
```

```
svm3 = e1071::svm(formula=default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_
```

```
pred.svm3 = predict(svm3, trainTransformado)
predTs.svm3 = predict(svm3, testTransformado)
Ein.svm3 = mean(pred.svm3 != trainTransformado$default.payment.next.month)
Eout.svm3 = mean(predTs.svm3 != testTransformado$default.payment.next.month)
Ein.svm3
```

```
## [1] 0.1557142857
```

```
Eout.svm3
```

```
## [1] 0.1851111111
```

```
svm4 = e1071::svm(formula=default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_
```

```
pred.svm4 = predict(svm4, trainTransformado)
predTs.svm4 = predict(svm4, testTransformado)
Ein.svm4 = mean(pred.svm4 != trainTransformado$default.payment.next.month)
Eout.svm4 = mean(predTs.svm4 != testTransformado$default.payment.next.month)
Ein.svm4
```

```
## [1] 0.09571428571
```

```
Eout.svm4
```

```
## [1] 0.2112222222
```


Para estos cuatro modelos, el mejor de todos ellos es el primero, ya que tiene el error fuera de la muestra más bajo. Además, la diferencia entre el error dentro de la muestra y el error fuera de la muestra no es grande por lo que sabemos que el modelo no tiene sobreajuste.

Ahora, calcularemos las probabilidades del modelo que hemos elegido y calcularemos su curva ROC y su área.

```
s.svm = e1071::svm(formula=default.payment.next.month~PAY_1+PAY_2+BILL_AMT1+LIMIT_BAL+AGE+ed.school+PAY_
pred.s = predict(s.svm, testTransformado, probability=T)
probs.svm = attr(pred.s, "probabilities")[,1]
svm.model = ROCR::prediction(probs.svm, testTransformado$default.payment.next.month)
perf = performance(svm.model, "tpr", "fpr")
auc.svm = performance(svm.model, measure = "auc")
print(auc.svm@y.values[[1]])
```

```
## [1] 0.7062206547
```

```
plot(perf)
```



Modelos con randomForest

Para los modelos de Random Forest, utilizaremos la función `randomForest`. Utilizaremos diferentes valores para el número de árboles que usa este método; el número de nodos será siempre el mismo, 400. Una vez hayamos evaluado todos los modelos, elegiremos el que menor error fuera de la muestra cometa y calcularemos la curva ROC de este.

```
n <- c("PAY_1", "PAY_2", "BILL_AMT1", "LIMIT_BAL", "AGE", "ed.school", "PAY_AMT1", "PAY_5", "marriage.married")
rf = randomForest::randomForest(x=trainTransformado[, names(trainTransformado)%in%n], y=as.factor(trainTransformado$default.payment.next.month))

pred.rf1 = predict(rf, trainTransformado)
Ein.rf1 = mean( pred.rf1 != trainTransformado$default.payment.next.month)
Ein.rf1

## [1] 0.1613333333

predTs.rf1 = predict(rf, testTransformado)
Eout.rf1 = mean( predTs.rf1 != testTransformado$default.payment.next.month)
Eout.rf1

## [1] 0.1824444444

rf2 = randomForest::randomForest(x=trainTransformado[, names(trainTransformado)%in%n], y=as.factor(trainTransformado$default.payment.next.month))

pred.rf2 = predict(rf2, trainTransformado)
```

```
Ein.rf2 = mean( pred.rf2 != trainTransformado$default.payment.next.month)
Ein.rf2
```

```
## [1] 0.161
```

```
predTs.rf2 = predict(rf2, testTransformado)
Eout.rf2 = mean( predTs.rf2 != testTransformado$default.payment.next.month)
Eout.rf2
```

```
## [1] 0.182
```

```
rf3 = randomForest::randomForest(x=trainTransformado[, names(trainTransformado)%in%n], y=as.factor(trainTransformado$default.payment.next.month))
```

```
pred.rf3 = predict(rf3, trainTransformado)
Ein.rf3 = mean( pred.rf3 != trainTransformado$default.payment.next.month)
Ein.rf3
```

```
## [1] 0.1608571429
```

```
predTs.rf3 = predict(rf3, testTransformado)
Eout.rf3 = mean( predTs.rf3 != testTransformado$default.payment.next.month)
Eout.rf3
```


```
## [1] 0.1825555556
```

El primer modelo es el mejor de los 3, ya que comete un error muy parecido al resto de los modelos utilizando menos árboles para ello. Ahora calcularemos la curva ROC y su área debajo de la curva.

```
probs = predict(rf, testTransformado, type="prob")
probs.pred = probs[,2]
rf.model = ROCR::prediction(probs.pred, testTransformado$default.payment.next.month)
perf = performance(rf.model, "tpr", "fpr")
auc.rf = performance(rf.model, measure = "auc")
print(auc.rf@y.values[[1]])
```

```
## [1] 0.7555162531
```

```
plot(perf)
```



Conclusiones.

Los resultados obtenidos por los clasificadores son los siguientes:

Área debajo de la curva ROC Clasificador: Área:

Lineal: 0.7182 Boosting: 0.6797 SVM: 0.7062 Redes Neuronales: 0.5492 Random Forest: 0.7523

Como podemos ver, el clasificador que mejores resultados obtiene es el Random Forest, el siguiente mejor clasificador es el lineal. Por lo tanto el mejor modelo posible es el que utiliza Random Forest, pero el modelo lineal también obtiene bastante buenos resultados, por lo también podríamos considerar utilizar este modelo ya que es más sencillo.

Además, creemos que un modelo de redes neuronales con los parámetros adecuados, y con la el tiempo suficiente para entrenarlas; podría obtener unos resultados parecidos a los que se obtienen con el resto de los modelos.